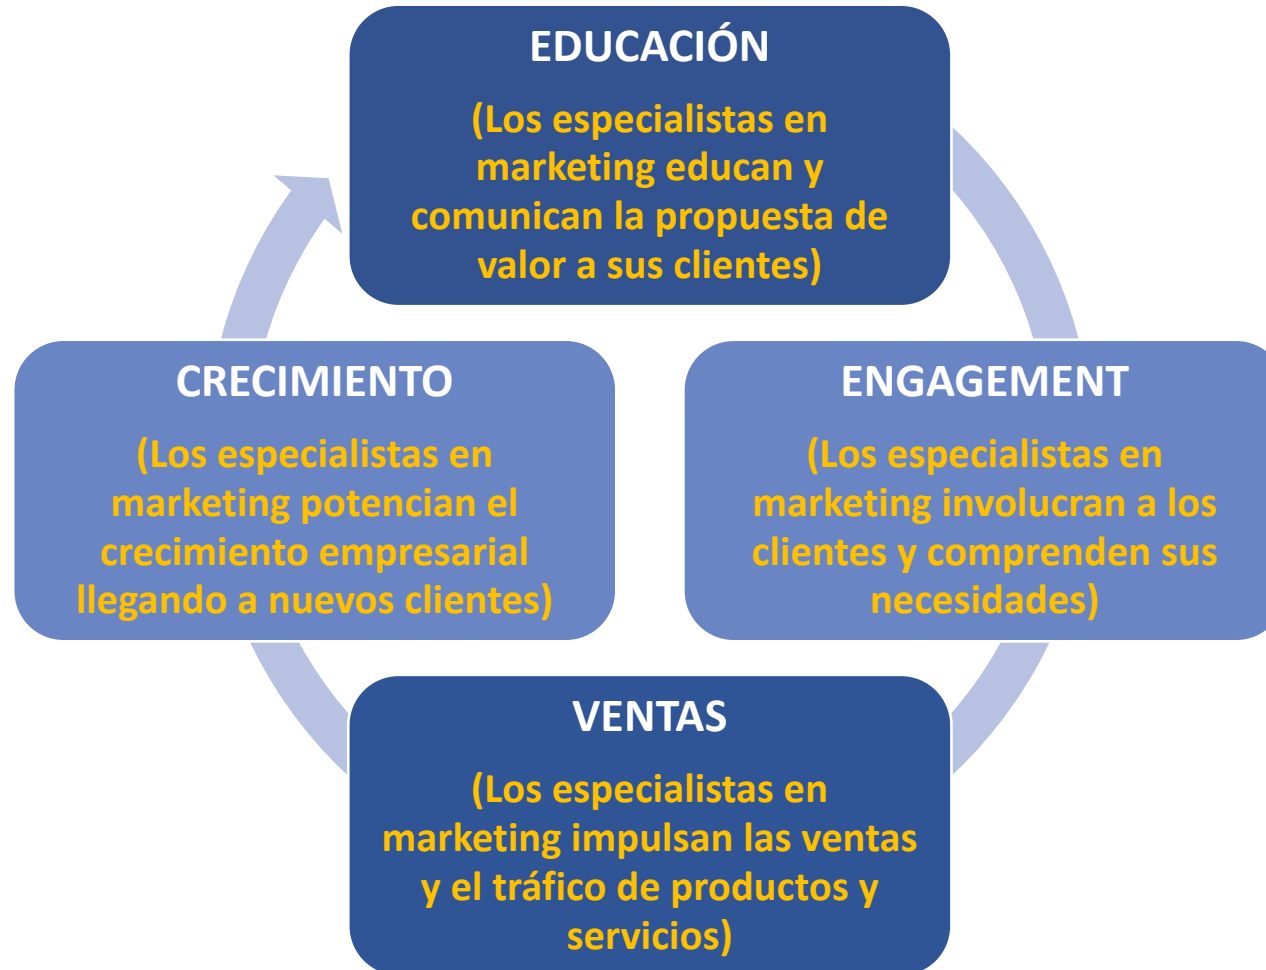


- El marketing es fundamental para el crecimiento y la sostenibilidad de cualquier negocio.
- Los especialistas en marketing pueden ayudar a desarrollar la marca de la empresa, atraer clientes, aumentar los ingresos y aumentar las ventas.



- Uno de los puntos críticos para los especialistas en marketing es conocer a sus clientes e identificar sus necesidades.
- Al comprender al cliente, los especialistas en marketing pueden lanzar una campaña de marketing dirigida que se adapte a necesidades específicas.
- Si los datos sobre los clientes están disponibles, la ciencia de datos se puede aplicar para realizar la segmentación del mercado.
- En este caso práctico, nos han contratado como expertos en data science para una empresa de minorista de análisis de Seattle, U.S..
- La empresa tiene muchos datos de sus clientes de los últimos 2 años y medio.
- Se nos encomienda la tarea de crear campañas de marketing enfocadas a los clientes, dividiéndolos para ello en por lo menos 3 segmentos diferentes



Fuente: <https://www.needpix.com/photo/896541/analytics-data-analytics-graph-chart-analysis-business-data-statistics-analyzing>



- **# ORDERNUMBER:** Identificador del pedido
- **# QUANTITYORDERED:** Número de ítems comprados
- **# PRICEEACH:** Precio de cada ítem
- **# SALES:** Total de ventas efectuads
- **# ORDERDATE:** Fecha del pedido realizado
- **# STATUS:** Estado del pedido
- **# QTR\_ID:** Trimestre en el que se hace el pedido
- **# MONTH\_ID:** Mes en el que se hace el pedido
- **# YEAR\_ID :** Año en el que se hace el pedido
- **# PRODUCTLINE:** Categoría del Producto
- **# CUSTOMERNAME:** Nombre del cliente
- **# PHONE:** Número de teléfono

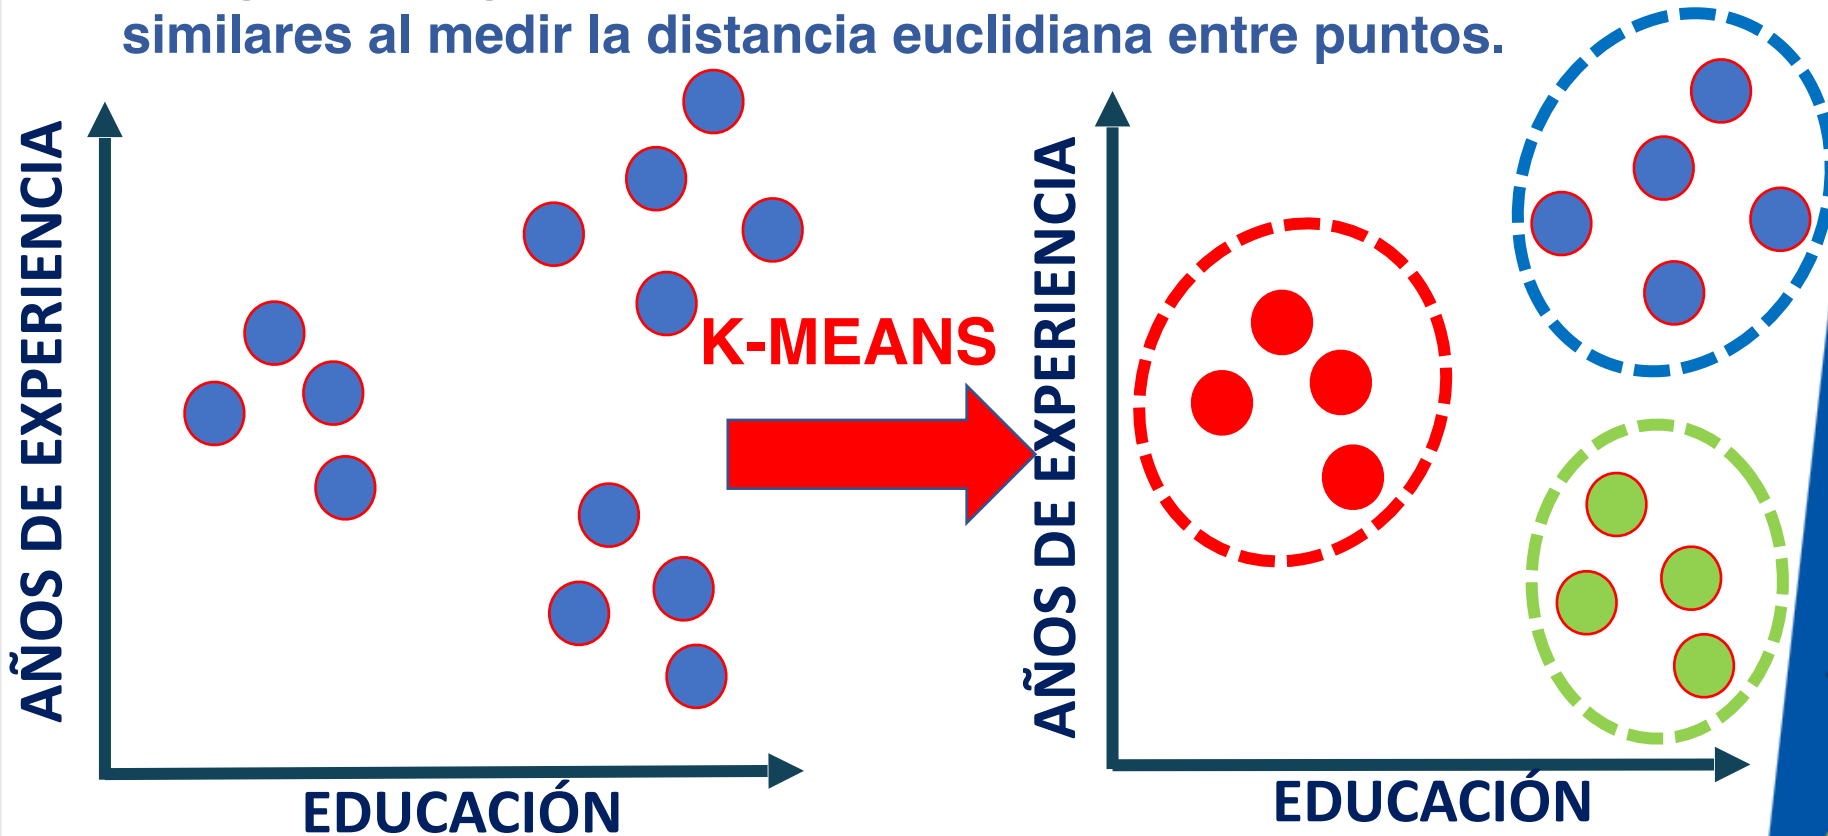


- **# ADDRESSLINE1:** Dirección de envío
- **# ADDRESSLINE2:** Dirección de envío
- **# CITY:** Ciudad en la que reside el cliente
- **# STATE:** Estado en el que reside el cliente
- **# POSTALCODE:** Código postal del cliente
- **# COUNTRY:** País en el que reside el cliente
- **# TERRITORY:** Territorio en el que reside el cliente
- **# DEALSIZE:** Tamaño del pedido
- **# CONTACTFIRST NAME:** Nombre del contacto
- **# CONTACTLAST NAME:** Apellido del contacto



# INTUICIÓN DETRÁS DE K-MEANS

- K-means es un algoritmo de aprendizaje no supervisado (clustering).
- K-means funciona agrupando algunos puntos de datos (clustering) de forma no supervisada.
- El algoritmo agrupa las observaciones con valores de atributos similares al medir la distancia euclidiana entre puntos.




# PASOS DEL ALGORITMO DE K-MEANS

1. Elegir el número de clústers "K"
2. Seleccionar K puntos aleatorios que serán los centroides de cada cluster
3. Asignar cada punto del dataset al centroide más cercano, hacerlo nos permitirá crear un número "K" de clústers con dichos puntos
4. Calcular un nuevo centroide para cada cluster
5. Reasignar cada punto de datos al nuevo centroide más cercano
6. Ir al paso 4 y repetir.







AÑOS DE EXPERIENCIA




AÑOS DE EXPERIENCIA



AÑOS DE EXPERIENCIA




AÑOS DE EXPERIENCIA



# ¿CÓMO SELECCIONAR EL NÚMERO ÓPTIMO DE CLÚSTERS (K)? "MÉTODO DE CODO"

$$\text{Within Cluster Sum of Squares (WCSS)} = \sum_{P_i \text{ in Cluster 1}} \text{distance}(P_i, C_1)^2 + \sum_{P_i \text{ in Cluster 2}} \text{distance}(P_i, C_2)^2 + \sum_{P_i \text{ in Cluster 3}} \text{distance}(P_i, C_3)^2$$

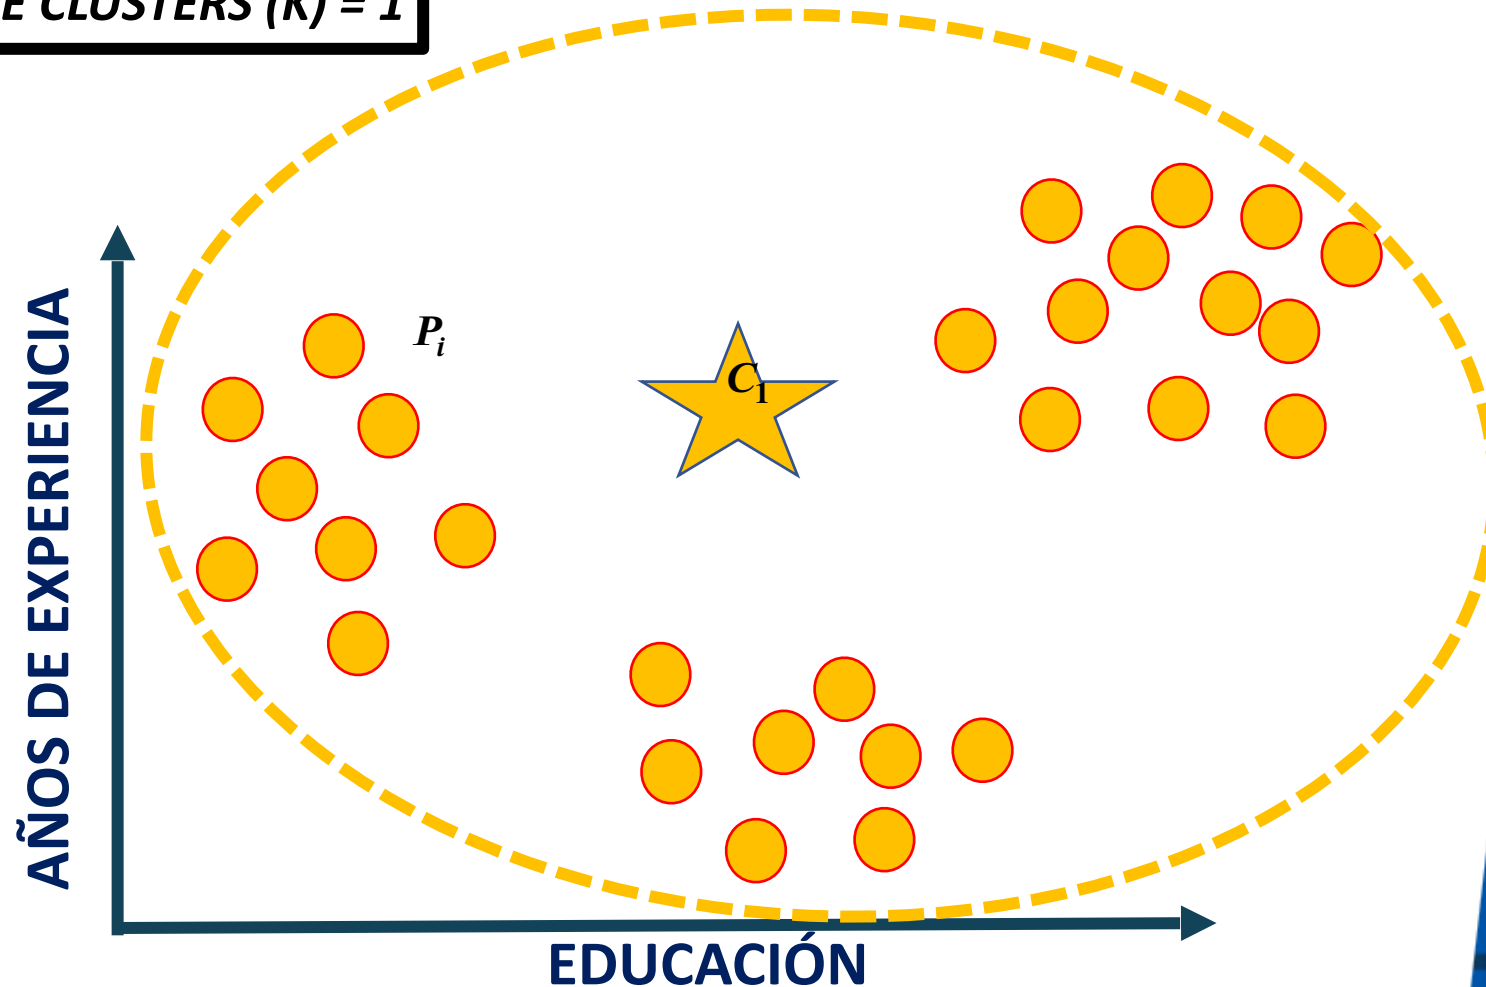




# ¿CÓMO SELECCIONAR EL NÚMERO ÓPTIMO DE CLÚSTERS (K)? "MÉTODO DE CODO"

$$\text{Within Cluster Sum of Squares (WCSS)} = \sum_{P_i \text{ in Cluster } 1} \text{distance}(P_i, C_1)^2$$


**NÚMERO DE CLUSTERS (K) = 1**



# ¿CÓMO SELECCIONAR EL NÚMERO ÓPTIMO DE CLÚSTERS (K)? "MÉTODO DE CODO"

$$\text{Within Cluster Sum of Squares (WCSS)} = \sum_{P_i \text{ in Cluster 1}} \text{distance}(P_i, C_1)^2 + \sum_{P_i \text{ in Cluster 2}} \text{distance}(P_i, C_2)^2$$

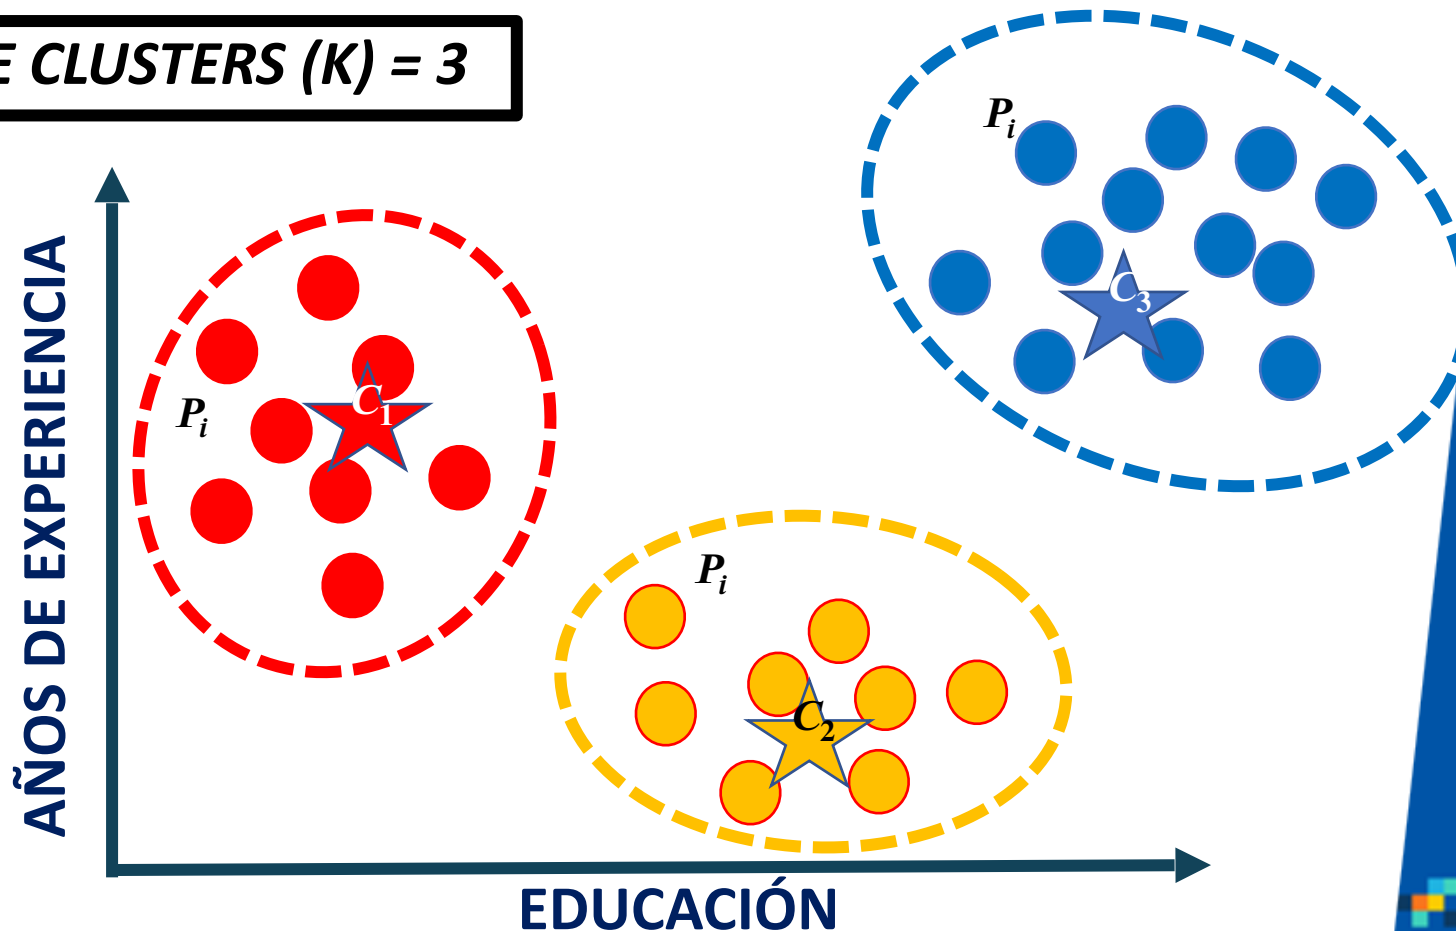
**NÚMERO DE CLUSTERS (K) = 2**




# ¿CÓMO SELECCIONAR EL NÚMERO ÓPTIMO DE CLÚSTERS (K)? "MÉTODO DE CODO"

$$\text{Within Cluster Sum of Squares (WCSS)} = \sum_{P_i \text{ in Cluster 1}} \text{distance}(P_i, C_1)^2 + \sum_{P_i \text{ in Cluster 2}} \text{distance}(P_i, C_2)^2 + \sum_{P_i \text{ in Cluster 3}} \text{distance}(P_i, C_3)^2$$

**NÚMERO DE CLUSTERS (K) = 3**



# ¿CÓMO SELECCIONAR EL NÚMERO ÓPTIMO DE CLÚSTERS (K)? "MÉTODO DE CODO"




Source: [https://commons.wikimedia.org/wiki/File:Tennis\\_Elbow\\_Illustration.jpg](https://commons.wikimedia.org/wiki/File:Tennis_Elbow_Illustration.jpg)



# INTUICIÓN DETRÁS DE LOS AUTOENCODERS

- Los autoencoders son un tipo de redes neuronales artificiales que se utilizan para realizar una tarea de codificación de datos (representation learning).
- Los autoencoders utilizan los mismos datos del dataset para la entrada y la salida. Suena loco, ¿verdad?



Crédito: [https://commons.wikimedia.org/wiki/File:Autoencoder\\_structure.png](https://commons.wikimedia.org/wiki/File:Autoencoder_structure.png)

Crédito: [https://commons.wikimedia.org/wiki/File:Artificial\\_neural\\_network\\_image\\_recognition.png](https://commons.wikimedia.org/wiki/File:Artificial_neural_network_image_recognition.png)

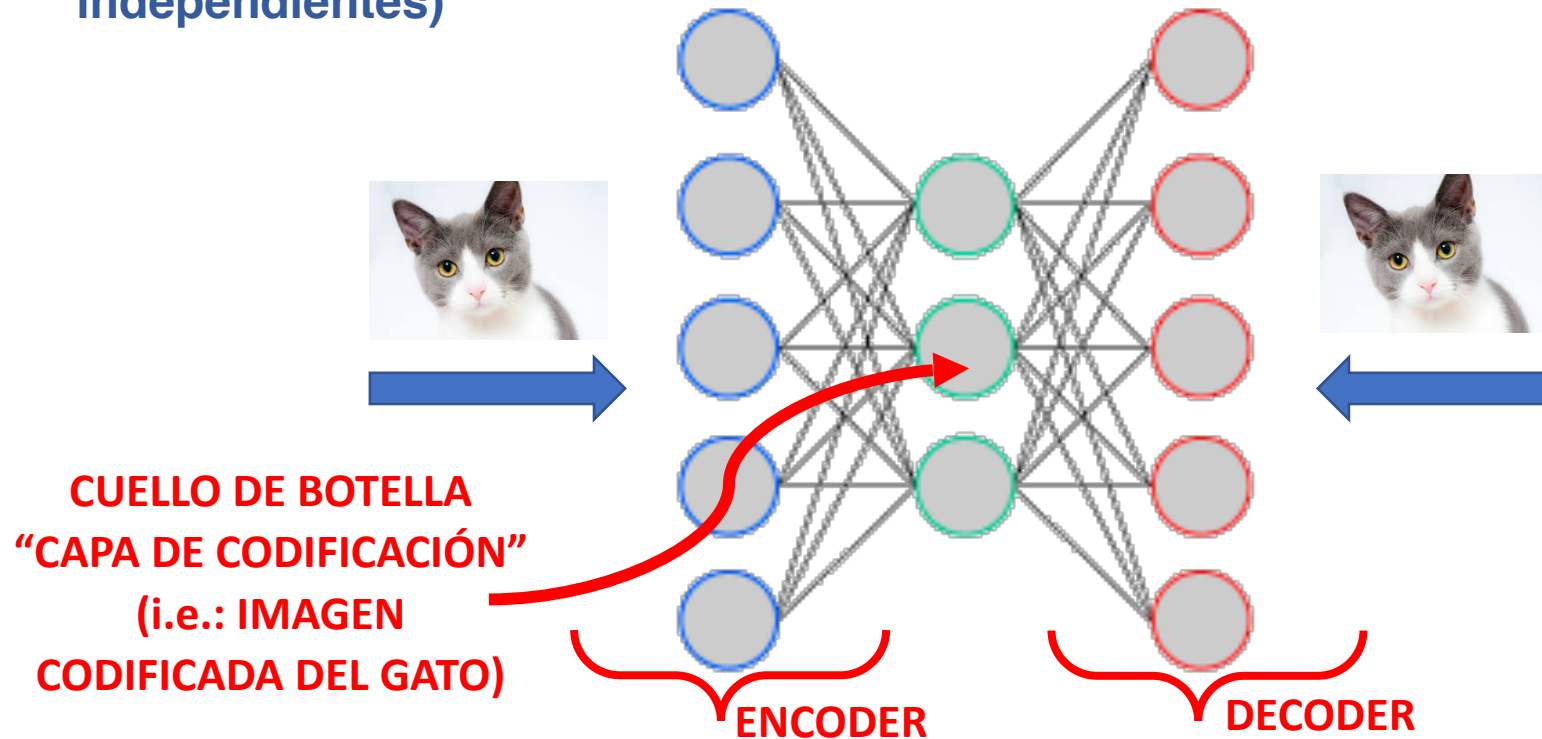
Crédito: <https://www.pexels.com/photo/grey-and-white-short-fur-cat-104827/>





# LA CAPA DE CODIFICACIÓN

- Los autoencoders funcionan agregando un cuello de botella en la red.
- Este cuello de botella obliga a la red a crear una versión comprimida (codificada) de la entrada original.
- Los autoencoders funcionan bien si existen correlaciones entre los datos de entrada (funcionan mal si todos los datos de entrada son independientes)



Crédito: [https://commons.wikimedia.org/wiki/File:Autoencoder\\_structure.png](https://commons.wikimedia.org/wiki/File:Autoencoder_structure.png)


Crédito: [https://commons.wikimedia.org/wiki/File:Artificial\\_neural\\_network\\_image\\_recognition.png](https://commons.wikimedia.org/wiki/File:Artificial_neural_network_image_recognition.png)

Crédito: <https://www.pexels.com/photo/grey-and-white-short-fur-cat-104827/>





# LAS MATEMÁTICAS DEL AUTOENCODER



## ENCODER:

$$h(x) = \text{sigmoid}(W * x + b)$$

## DECODER:

$$\hat{x} = \text{sigmoid}(W^* * h(x) + c)$$

## PESOS LIGADOS:

Los pesos de la entrada a la capa oculta serán iguales a los pesos de la capa oculta a la salida

$$W^* = W^T$$

Crédito: [https://commons.wikimedia.org/wiki/File:Autoencoder\\_structure.png](https://commons.wikimedia.org/wiki/File:Autoencoder_structure.png)

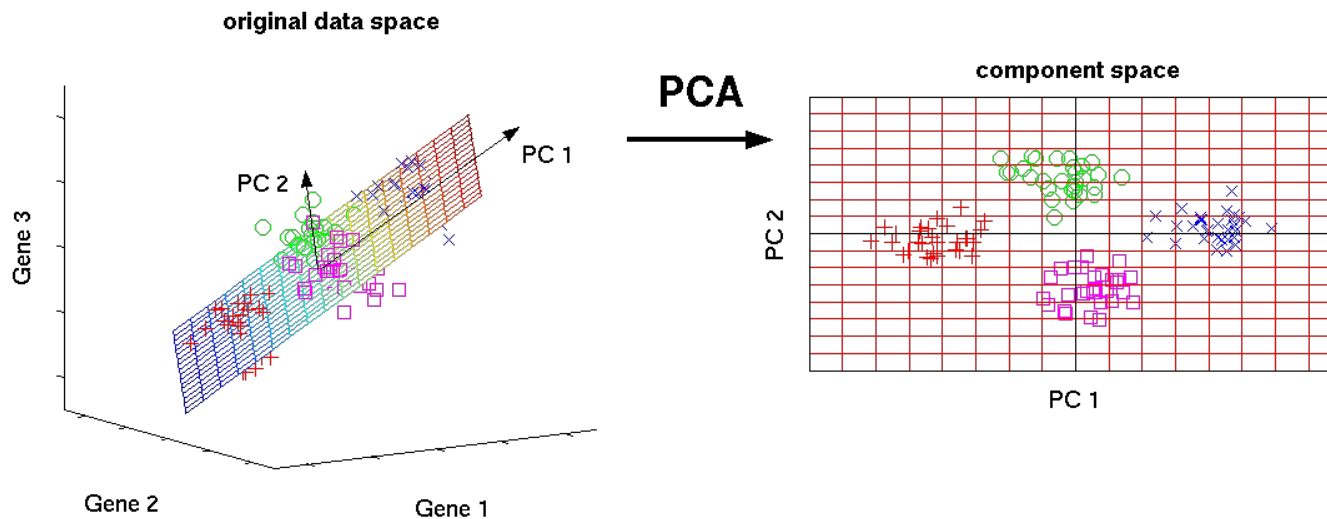
Crédito: [https://commons.wikimedia.org/wiki/File:Artificial\\_neural\\_network\\_image\\_recognition.png](https://commons.wikimedia.org/wiki/File:Artificial_neural_network_image_recognition.png)

Crédito: <https://www.pexels.com/photo/grey-and-white-short-fur-cat-104827/>



# REPASO DEL ANÁLISIS DE COMPONENTES PRINCIPALES

- PCA es un algoritmo de aprendizaje automático no supervisado.
- PCA realiza reducciones de dimensionalidad mientras intenta mantener la información original sin cambios.
- PCA funciona tratando de encontrar un nuevo conjunto de características llamadas componentes.
- Los componentes son compuestos de las características de entrada 0no correlacionadas entre si.



Crédito: <http://phdthesis-bioinformatics-maxplanckinstitute-molecularplantphys.matthias-scholz.de/>

